미래 | me-Reh

실시간 음성 반응형 배리어프리 자막 시스템 — AI 연구자 협업 기획서

문서 버전: 1.0 · 기준일: 2026년 10월 23일 · 프로젝트 기획: 김경민 · 상태: 연구 협업 제안 및 실험용 MVP

1. 제안 개요

〈미래 | me-Reh〉는 발화자의 말을 실시간 자막으로 전환하면서 음량과 음높이 같은 측정 가능한 음향 특성을 글자의 크기·굵기·위치 등 시각적 속성과 연결하는 배리어프리 문화기술 프로젝트다. 문장만 전달하는 자막을 넘어서 발화 방식에 대한 시각적 단서를 더하되, 정확한 정보 전달과 이용자별 가독성을 표현 효과보다 우선한다. 초기 대상 환경은 공연·전시·교육 현장이다.

협업 목적: 재현 가능한 MVP와 제작 문서를 AI 연구자에게 공유하여 실시간 인식 품질, 신호-문장 동기화, 접근성 평가 및 로컬 추론 구조를 공동 검증한다.

2. 문제 정의와 목표

- 현재 자막에서는 발화 내용은 읽을 수 있지만 목소리의 강약·높낮이와 같은 일부 발화 특징을 충분히 표현하기 어렵다.
- 지나친 글자 움직임이나 질감 효과는 읽기 경험을 해칠 수 있으므로, 사용자 제어와 접근성 안전 장치가 필수다.
- 실시간 음성 인식 결과와 음향 분석 데이터가 서로 다른 시간 경로에서 도착하므로, 정확한 정렬이 연구 과제다.
- 공연의 동시 발화 상황은 단일 브라우저 음성 인식 세션으로 안정적 분리하기 어렵다.

성공의 정의(제안·검증 필요): 실시간 자막 제공, 명확한 발화자 귀속, 제어 가능한 시각 반응, 여러 언어에서 읽기 쉬운 표현, 기록/개인정보에 대한 이용자 선택권.

3. 창작·인터랙션 원칙

1. 내용 우선: 자막 텍스트 자체를 안정적으로 읽을 수 있어야 한다.

2. 음향과 감정의 구별: 음량·기본 주파수의 변화를 표현하되 사람의 감정을 판정했다고 주장하지 않는다.

3. 화자 정체성: 화자 A/B가 별도의 글꼴·텍스처·색상·기준 크기·굵기·반응 강도를 선택할 수 있다.

4. 다양한 접근 방식: 움직임 감소, 고대비, 가독성 중심 모드를 구분해 연구한다.

5. 공유 가능한 제작: 코드와 설계도, 가설과 실험 결과를 버전별로 기록한다.

4. 시스템 구조(현재)

마이크 입력을 기준으로 ① Web Speech API에 의한 중간/최종 인식 문자열과 ② Web Audio API에 의한 RMS 음량·자기상관 기반 음높이 추정 데이터를 처리한다. 현재 선택된 화자의 스타일 프로필을 적용하여 자막 글자 크기·굵기·수직 위치를 계산하고, 한 화면에서 텍스트와 스타일을 함께 표시한다. 화자 전환은 수동이며, 두 마이크 동시 인식이나 자동 화자 식별은 구현되지 않았다.

- 언어 선택: 한국어(`ko-KR`), 영어(`en-US`), 일본어(`ja-JP`)
- 글꼴: 추천 Google Fonts, 이름 직접 입력, WOFF/WOFF2/TTF/OTF 불러오기

- 텍스처: 단색을 포함해 9종; CSS 그라디언트 기반
- 음향 반응: 음량은 글자 크기·굵기, 음높이는 미세 수직 변화
- 화자: A/B 수동 전환 및 스타일별 관리

중요한 구현 한계: Web Speech API 음성 인식은 브라우저·네트워크 조건에 의존할 수 있으며, 현재 로컬 HTML 버전은 음성 인식 모델이 내장된 완전 오프라인 솔루션이 아니다. `getUserMedia()`의 마이크 오디오와 `SpeechRecognition` 내부 인식 데이터도 타임스탬프 수준으로 동기화되어 있지 않다.

5. 버전 현황과 연구 로드맵

버전	주요 내용	단계
v0.2	단일 화자·3개 언어·웹폰트	구현
v0.2.1	수동 화자 전환·화자별 페르소나	구현
v0.2.2	UI 개선·질감 9종	구현
v0.2.3 로컬 패키지	설정 브라우저 저장·JSON 가져오기/내보내기·TXT 자막 기록·움직임 감소	코드 구성 및 구문 검사, 실기기 검증 필요
v0.3	복수 마이크 입력 채널 및 정확한 화자 귀속	계획
v0.4	faster-whisper 등 별도 로컬 음성 인식 서비스	계획
v0.5	영상 시스템 연동 및 자막 안전 영역 제어	계획
v1.0	이용자 공동 평가·현장 실증 및 공개	계획

6. AI 연구자와 공동 해결할 과제

R1. 음성 인식 정확성: 한국어·영어·일본어별 WER/CER 측정, 주변 소음·반향·발화 속도 실험. Web Speech와 로컬 STT 비교.

R2. 동기화: 발화 구간별 타임스탬프·오디오 버퍼·인식 결과 매칭, 지연시간(p50/p95) 및 자막 반응의 시차 측정.

R3. 다중 화자: 복수 장치 동시 캡처, 입력 채널 격리, 음성 인식 분리, 화자별 기록 혼선 및 중첩 발화 정책.

R4. 음향-타이포그래피 매핑: RMS 정규화, F0 신뢰도, 조용한 목소리의 과소표현 방지, 범위 제한과 보정값 비교.

R5. 접근성: 당사자 참여형 읽기 평가, 텍스처 대비, 화면 넘침, 동작 민감도, 화자 식별을 위한 색상 외 정보 검증.

R6. 로컬 개인정보: 음성의 외부 전송 여부 설명, 기록 동의·삭제, 저장 기간, 파일 공유 전 비식별화.

7. 제공하는 로컬 MVP 패키지

- `me-Reh_MVP_local_v0.2.3.html` — 단일 HTML 앱. 로컬 파일에서 열거나 `localhost`에서 실행.
- `README_실행안내.md` — 실행, 설정 보관, 한계 및 데이터 정책.

- `01_버전로드맵.png`, `02_핵심메커니즘.png` — 공유받은 설계 이미지.
- 본 협업 기획서 및 `연구실험_기록양식.md`.

로컬 저장 내용: 화자별 색상·크기·텍스처·반응성·웹폰트 이름, 인식 언어 및 화면 설정은 사용자가 '설정 로컬 저장'을 누르면 브라우저 `localStorage`에 저장된다. 자막 기록은 명시적 선택 시에만 최대 20개 최근 항목을 저장한다. 설정은 JSON 파일로, 인식된 자막 기록은 TXT 파일로 직접 다운로드할 수 있다. 업로드된 로컬 폰트 파일의 바이트는 설정 JSON에 포함되지 않으므로 파일을 다시 선택해야 한다.

8. 연구 결과 평가 계획(제안)

영역	기록 지표	시험 조건 예시
음성 인식	CER/WER, 인식 누락률	3개 언어, 조용한 방/반향 공간
지연	음성 시작→자막 표시 지연, 스타일 반응 지연	p50·p95
화자	잘못 귀속된 자막 비율	순차 발화, 중첩 발화
가독성	문장 읽기 시간, 오독률, 주관적 피로도	고정/반응형/고대비 비교
성능	CPU 점유·프레임 변동·브라우저 호환성	데스크톱·노트북
개인정보	권한 거부, 저장·삭제·내보내기 동작	네트워크 단절 포함

위 지표들은 목표가 아니라 공동 연구를 위한 제안 항목이며, 측정값은 아직 확보되지 않았다.

9. 협업 및 권리 원칙(초안)

프로젝트명과 기존 기획 원안, 기존 코드·도면의 권리관계는 공개 전 정리한다. 외부 연구자가 기여한 코드·알고리즘·저작물에는 작성자와 날짜, 기여 범위를 기록하고, 공개 라이선스 및 공동 저작/발명 여부는 당사자 협의 후 결정한다. 본 패키지는 연구용 검토본이며 현재 공개 오픈소스 라이선스가 부여된 것은 아니다. 기획서·도면·코드 공유는 향후 특허 검토 대상 기술의 신규성에 영향을 줄 수 있으므로 공개 범위를 먼저 확인한다.

10. 협력 요청

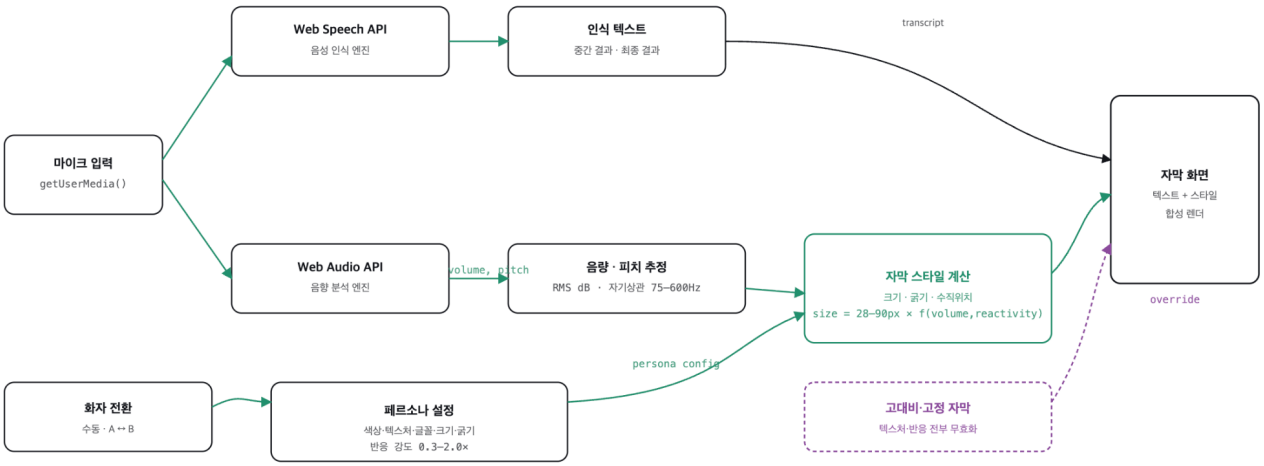
실시간 음성 인식, 오디오 신호 처리, 웹 인터랙션, 접근성/UX 연구 및 공연 영상 시스템 전문가의 기술 검토와 실험 설계를 요청한다. 실험 제안은 `연구실험_기록양식.md`에 정리하고, 코드 수정은 버전과 기여자를 기록하여 공유한다.

별첨 · 설계 도면

01_버전로드맵.png

핵심 메커니즘

실제 구현(me-Reh_MVP_v0.2.2.html)의 신호 흐름을 그대로 옮긴 다이어그램입니다.



두 경로(인식 텍스트 / 음량·피치)와 화자별 페르소나 설정이 합쳐져 자막 스타일을 매 프레임 계산한다. 고대비 모드를 켜면 이 계산을 건너뛰고 흰색 고정 표시로 강제 전환된다 — 장식보다 가독성을 우선하는 유일한 예외 경로다.

02_핵심메커니즘.png

버전 로드맵

현재 위치(v0.2.2)와 다음 과제.



동시 다중화자(v0.3)와 로컬 STT(v0.4)는 Web Speech API가 마이크 입력 장치를 지정할 수 없다는 현재 구조의 한계를 넘어서야 하는 단계다.